

Выпускная квалификационная работа

Сравнительный анализ SMO и MDM алгоритмов машинного обучения

Научный руководитель

Соловьева Наталья Анатольевна

должность, ученая степень, ученое звание


Подготовил

Коваленко Анатолий Фёдорович

ПМ-2201



Цель работы




Цель работы – провести сравнительное исследование алгоритмов обучения линейного бинарного классификатора Рассматриваемые методы:

- ▶ **SVM (Support Vector Machine)** – метод опорных векторов, строящий разделяющую гиперплоскость максимальной ширины;
- ▶ **SMO (Sequential Minimal Optimization)** – последовательная минимальная оптимизация двойственной задачи SVM;
- ▶ **MDM (Mitchell–Demyanov–Malozemov)** – геометрический метод поиска ближайших точек выпуклых оболочек.



Постановка задачи исследования



Дано множество объектов, каждый из которых описывается вектором признаков и меткой одного из двух классов:

$$(p_1, \xi_1), \dots, (p_m, \xi_m), \quad p_j \in \mathbb{R}^n, \quad \xi_j \in \{-1, +1\}.$$


Необходимо построить линейный классификатор

$$\hat{\xi}(p) = \text{sgn}(\langle w, p \rangle + \beta),$$

- ▶ p – вектор признаков объекта;
- ▶ w – вектор параметров классификатора;
- ▶ β – свободный член, задающий смещение разделяющей гиперплоскости;
- ▶ $\langle w, p \rangle + \beta = 0$ – разделяющая гиперплоскость;
- ▶ $\text{sgn}(\cdot)$ – правило отнесения объекта к одному из двух классов.




Задача классификации в двумерном случае






Задача классификации в трёхмерном случае


$$\hat{\xi}(p) = \text{sgn}(\langle \mathbf{w}, \mathbf{p} \rangle + \beta) = \text{sgn}(w_1x_1 + w_2x_2 + w_3x_3 + \beta)$$





Метод опорных векторов (support vector machine, SVM)

Строгое и мягкое линейное отделение



Рассмотрим два конечных множества точек и метки классов:


$$P_1 = \{p_j\}_{j=1}^s, \quad P_2 = \{p_j\}_{j=s+1}^m, \quad \xi_j = \begin{cases} +1, & j = 1, \dots, s, \\ -1, & j = s+1, \dots, m. \end{cases}$$

Гиперплоскость задаётся уравнением

$$\langle w, p \rangle + \beta = 0, \quad w \in \mathbb{R}^n, \quad w \neq 0.$$

Множества P_1 и P_2 допускают строгое линейное отделение, если существуют $w \neq 0$ и β , такие что

$$\begin{aligned} \langle w, p_j \rangle + \beta &> 0, \quad j = 1, \dots, s, \\ \langle w, p_j \rangle + \beta &< 0, \quad j = s+1, \dots, m. \end{aligned}$$



Одна и та же гиперплоскость не имеет единственной записи:

$$\langle w, p \rangle + \beta = 0 \iff \langle cw, p \rangle + c\beta = 0, \quad c > 0.$$

Чтобы зафиксировать масштаб параметров, вводят нормированные условия:


$$\langle w, p_j \rangle + \beta \geq 1, \quad j = 1, \dots, s, \quad \langle w, p_j \rangle + \beta \leq -1, \quad j = s + 1, \dots, m.$$

Или, используя метки классов:

$$\xi_j(\langle w, p_j \rangle + \beta) \geq 1, \quad j = 1, \dots, m.$$



Границы разделяющей полосы



В нормированной записи рассматриваются три параллельные гиперплоскости:

$$L_1 : \langle w, p \rangle + \beta = 1,$$


$$L_0 : \langle w, p \rangle + \beta = 0,$$

$$L_2 : \langle w, p \rangle + \beta = -1.$$

- L_0 – разделяющая гиперплоскость;
- L_1 и L_2 – границы разделяющей полосы.

Можно доказать, что расстояние между границами равно

$$h = \rho(L_1, L_2) = \frac{2}{\|w\|}.$$



В канонической нормировке задача SVM записывается как


$$\min_{w, \beta} \frac{1}{2} \|w\|^2,$$

$$\xi_j(\langle w, p_j \rangle + \beta) \geq 1, \quad j = 1, \dots, m.$$

- ▶ $w \in \mathbb{R}^n, \beta \in \mathbb{R}$ – параметры гиперплоскости;
- ▶ $\langle w, p \rangle + \beta = 0$ – разделяющая гиперплоскость;
- ▶ минимизация $\frac{1}{2} \|w\|^2$ эквивалентна максимизации ширины полосы.



Двойственная задача SVM



Для строгого отделения лагранжиан имеет вид

$$\mathcal{L}(w, \beta, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{j=1}^m \alpha_j (\xi_j (\langle w, p_j \rangle + \beta) - 1).$$

Условия стационарности дают


$$w = \sum_{j=1}^m \alpha_j \xi_j p_j, \quad \sum_{j=1}^m \alpha_j \xi_j = 0.$$

Поэтому задача переходит к поиску коэффициентов α_j :

$$\frac{1}{2} \langle A_0^T A_0 \alpha, \alpha \rangle - \sum_{j=1}^m \alpha_j \rightarrow \min, \quad \sum_{j=1}^m \xi_j \alpha_j = 0, \quad \alpha_j \geq 0.$$



Опорные векторы




Обведённые точки лежат на границах разделяющей полосы.

Для них выполняется

$$\alpha_j > 0.$$

Именно они входят в представление нормали w^* .



Вводятся переменные нарушений:

$$\xi_j(\langle w, p_j \rangle + \beta) \geq 1 - \eta_j, \\ \eta_j \geq 0.$$


Прямая задача:

$$\min_{w, \beta, \eta} \frac{1}{2} \|w\|^2 + C \sum_{j=1}^m \eta_j$$

Параметр C задаёт баланс между шириной полосы и штрафом за нарушения.



Двойственная задача мягкого отделения



Переменные нарушений добавляют верхнюю границу для двойственных коэффициентов:

$$0 \leq \alpha_j \leq C, \quad j = 1, \dots, m.$$

Двойственная постановка сохраняет тот же квадратичный функционал:

$$\frac{1}{2} \langle A_0^T A_0 \alpha, \alpha \rangle - \sum_{j=1}^m \alpha_j \rightarrow \min .$$

Но допустимое множество становится ограниченным:

$$\sum_{j=1}^m \xi_j \alpha_j = 0, \quad 0 \leq \alpha_j \leq C.$$


Это ограничивает влияние выбросов и объектов, попавших внутрь полосы.


Обобщенный метод MDM

Ближайшие точки выпуклых оболочек и восстановление
разделителя



MDM: ближайшие точки выпуклых оболочек





Каждому классу сопоставляются выпуклые оболочки

$$C_1 = \text{conv}\{p_1, \dots, p_s\}, \quad C_2 = \text{conv}\{p_{s+1}, \dots, p_m\}.$$


MDM ищет ближайшие точки этих оболочек:

$$\frac{1}{2} \|w_1 - w_2\|^2 \rightarrow \min, \quad w_1 \in C_1, \quad w_2 \in C_2.$$

Через единый план u это записывается как

$$Q(u) = \frac{1}{2} \|Au\|^2 \rightarrow \min, \quad u \in U.$$

Вектор Au является текущим направлением между двумя оболочками.



На итерации k текущий вектор $w_k = Au_k$ задает направление, по которому выбираются две точки внутри одного класса:

$$p'_k \in M_i^+(u_k), \quad p''_k \in M_i^-.$$

Величина


$$\Delta_k = \langle w_k, p'_k - p''_k \rangle$$

показывает, насколько можно уменьшить функционал переносом веса.

Если подходящего переноса уже нет, текущие точки оболочек удовлетворяют условию ближайшей пары и задают разделитель.



Итерационный шаг MDM



Перенос веса:


$$u_{k+1} = u_k + t_k u_{k,j} (e_{j'} - e_j).$$

Длина шага:

$$t_k = \min \left\{ \frac{\Delta_k}{u_{k,j} \|p_j - p_{j'}\|^2}, 1 \right\}.$$



Восстановление гиперплоскости в MDM



После нахождения ближайших точек

$$w_1^* \in C_1, \quad w_2^* \in C_2$$

нормаль разделителя равна


$$v = w_1^* - w_2^*.$$

Центр полосы:

$$c^* = \frac{w_1^* + w_2^*}{2}.$$


Гиперплоскость:

$$\langle v, p - c^* \rangle = 0.$$



MDM с мягким разделением

Ограниченные веса и восстановление гиперплоскости



Мягкая двойственная постановка задаёт допустимое множество

$$U = \left\{ u \in \mathbb{R}^m \mid \sum_{j=1}^m \xi_j u_j = 0, \ 0 \leq u_j \leq C \right\}.$$


Целевая функция:

$$D(u) = \frac{1}{2} \langle A^T A u, u \rangle - \sum_{j=1}^m u_j \rightarrow \min, \quad u \in U.$$

Верхняя граница $u_j \leq C$ ограничивает влияние отдельного объекта.



Переход к мягкому MDM



При пересечении классов ближайшие точки обычных оболочек уже не задают корректный разделитель. Поэтому используются ограниченные веса:

$$U_C = \left\{ u \in \mathbb{R}^m \mid \sum_{j=1}^m \xi_j u_j = 0, \ 0 \leq u_j \leq C \right\}.$$


Задача принимает вид

$$D(u) = \frac{1}{2} \langle A^T A u, u \rangle - \sum_{j=1}^m u_j \rightarrow \min, \quad u \in U_C.$$

Верхняя граница C не дает одному объекту полностью определить положение разделяющей гиперплоскости.



Итерационный шаг мягкого MDM



Шаг снова переносит вес между двумя координатами, но теперь учитывает нижнюю и верхнюю границы:

$$0 \leq u_j \leq C.$$

Направление выбирается по производным целевой функции:

$$q_j = \langle v, \xi_j p_j \rangle - 1, \quad v = Au.$$


Для рабочей пары берется допустимое изменение, сохраняющее баланс

$$\sum_{j=1}^m \xi_j u_j = 0.$$

Поэтому мягкий вариант сохраняет идею MDM-переноса веса, но работает уже не с двумя непересекающимися оболочками, а с ограниченным допустимым множеством коэффициентов.



Гиперплоскость в мягкой постановке



Нормаль после решения мягкой задачи восстанавливается по плану:

$$w^* = Au^* = \sum_{j=1}^m u_j^* \xi_j p_j.$$


Если найден объект с внутренним коэффициентом $0 < u_j^* < C$, то

$$\beta^* = \xi_j - \langle w^*, p_j \rangle.$$

Когда таких объектов нет, параметр β можно определить из одномерной вспомогательной задачи

$$f(\beta) = \sum_{j=1}^m [1 - \xi_j(\langle w^*, p_j \rangle + \beta)]_+ \rightarrow \min.$$

Это завершает переход от найденных коэффициентов к классификатору.




Модификации шага MDM

Групповой, треугольный, циклический и комбинированный варианты



Перенос веса в группу минимумов



В базовом MDM вес переносится к одной точке с минимальной проекцией.

В модификации строится множество

$$I_{\min} = \{j : \langle p_j, w_k \rangle = \min_i \langle p_i, w_k \rangle\}.$$

Вместо одной точки используется центр группы

$$\bar{p}_{\min} = \frac{1}{|I_{\min}|} \sum_{j \in I_{\min}} p_j.$$


Кандидат шага строится в направлении

$$d = \bar{p}_{\min} - p',$$

а длина шага выбирается так, чтобы сохранить допустимость весов и уменьшить $Q(u)$.



Геометрический треугольный шаг



Вместо движения по одному MDM-отрезку строятся несколько допустимых локальных направлений.

Пусть r_k и q_k – точки, полученные альтернативными переносами веса. Тогда рассматривается

$$T_k = \text{conv}\{w_k, r_k, q_k\}.$$



Следующая точка выбирается как проекция нуля:

$$\tilde{w}_k = \arg \min_{w \in T_k} \|w\|^2.$$

Если соответствующие веса допустимы, этот кандидат участвует в выборе шага.



Ускорение по повторяющимся циклам



Если последние направления
начинают повторяться,

$$s_k \approx s_{k-2}, \quad s_{k+1} \approx s_{k-1},$$

строится суммарное смещение

$$v_k = s_{k-2} + s_{k-1}.$$

Ускоренный кандидат задаётся
как


$$\tilde{w}_k = w_k + \rho_k v_k,$$

где ρ_k выбирается из условия
допустимости и уменьшения
 $Q(u)$.

Если такого уменьшения нет,
используется обычный
MDM-шаг.



Комбинированный выбор шага



Комбинированный вариант работает в той же допустимой области весов:

$$u \in \Delta, \quad 0 \leq u_j \leq C \quad \text{для мягкой постановки.}$$


На каждой итерации строится набор допустимых кандидатов $\mathcal{U}_k$:

- ▶ базовый перенос веса;
- ▶ групповой перенос;
- ▶ геометрический треугольный шаг;
- ▶ ускоренный шаг по циклу, если он доступен.

Выбор задаётся правилом


$$u_{k+1} = \arg \min_{u \in \mathcal{U}_k} Q(u).$$

Если дополнительные кандидаты не улучшают значение функционала, алгоритм возвращается к базовому MDM-шагу.



SМО-алгоритм

Парная оптимизация двойственной задачи SVM



В двойственной задаче SVM действует ограничение баланса


$$\sum_{j=1}^m \alpha_j \xi_j = 0.$$

Поэтому нетривиальный шаг должен менять минимум две координаты:

$$\alpha_{i'} \leftarrow \alpha_{i'} + \xi_{i'} \lambda, \quad \alpha_{i''} \leftarrow \alpha_{i''} - \xi_{i''} \lambda.$$

Вектор нормали обновляется рекуррентно:

$$v_{k+1} = v_k + \lambda(p_{i'} - p_{i''}).$$



SMO решает двойственную задачу SVM:

$$D(\alpha) = \frac{1}{2} \langle A_0^T A_0 \alpha, \alpha \rangle - \sum_{j=1}^m \alpha_j \rightarrow \min .$$

Допустимые планы должны сохранять баланс классов:

$$\sum_{j=1}^m \xi_j \alpha_j = 0.$$


В мягкой постановке добавляются ограничения

$$0 \leq \alpha_j \leq C.$$

Поэтому одиночное изменение коэффициента обычно невозможно: нужен парный шаг.



Парная подзадача SMO



На шаге выбираются индексы i' и i'' , а остальные коэффициенты считаются фиксированными:

$$\alpha_{i'} \leftarrow \alpha_{i'} + \xi_{i'} \lambda, \quad \alpha_{i''} \leftarrow \alpha_{i''} - \xi_{i''} \lambda.$$


Параметр λ находится из одномерной квадратичной задачи и затем усекается так, чтобы остались выполнены границы

$$0 \leq \alpha_{i'}, \alpha_{i''} \leq C.$$

Именно поэтому SMO удобен вычислительно: большая задача разбивается на последовательность очень малых подзадач.



Оптимальность и связь SMO с MDM



В реализации контролируется разрыв между допустимыми направлениями:

$$\Delta(\alpha) = \max_{j \in I''(\alpha)} q_j - \min_{j \in I'(\alpha)} q_j.$$


Остановка выполняется при

$$\Delta(\alpha) \leq \varepsilon.$$

Нормаль восстанавливается так же, как в двойственной SVM:


$$w^* = \sum_{j=1}^m \alpha_j^* \xi_j p_j.$$

По структуре шага SMO близок к MDM: оба метода меняют пару весов, но делают это в разных допустимых множествах.



Экспериментальное сравнение

Главный блок презентации: протокол, таблицы, графики и выводы




Сравнение проводилось в двух режимах.

- ▶ **Строгое отделение:** разделимые синтетические наборы S1–S4; метрики – итерации, время, ширина полосы, активные точки.
- ▶ **Мягкое отделение:** неразделимые синтетические наборы N1–N4 и реальные бинарные датасеты R1–R15; метрики – Test F1, ROC-AUC, время.

Для неразделимых и реальных данных использовалось стратифицированное разбиение 70/30. В мягкой постановке фиксировалось $C = 1$.




Типы данных в эксперименте







Методы и обозначения



Код	Метод	Смысл шага
H1	Базовый MDM	перенос веса между двумя точками
H2	SMO	парное изменение двойственных коэффициентов
H3	MDM-G	перенос в группу минимумов
H4	MDM-A	ускорение по повторяющимся циклам
H5	Треугольный MDM	выбор ближайшей точки локального треугольника
H6	Комбинированный MDM	выбор лучшего из нескольких кандидатов



Обозначения	Группа методов	Постановка
MDM, MDM-G, MDM-A SMO, SVC, LinearSVC	мягкие MDM-варианты SVM-решатели	ограничения $0 \leq u_j \leq C$ мягкая линейная постановка



Для мягкой постановки использовались две основные test-метрики:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}, \quad \text{ROC-AUC} = \int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}.$$

F1 фиксирует качество итоговой бинарной классификации, а ROC-AUC оценивает способность метода правильно ранжировать объекты.




Строгое отделение: средние результаты

Метод	Итерации	Время, с	Train acc.
Базовый MDM	672.4	0.0584	1.000
SMO	256.7	0.0068	1.000
MDM-G	690.2	0.0792	1.000
MDM-A	565.7	0.0719	1.000
Треугольный MDM	307.1	0.0533	1.000
Комбинированный MDM	217.1	0.1259	1.000






Строгое отделение: число итераций






Строгое отделение: время обучения








Относительное ускорение по итерациям






Влияние размера выборки






Влияние размерности: итерации






Влияние размерности: время






Контроль геометрического решения



d	Ширина MDM	Ширина SVC	Активные MDM	Опорные SVC
2	3.095	3.094	3.0	3.0
5	3.151	3.151	5.7	5.7
10	3.201	3.201	9.7	9.7
20	3.330	3.330	17.0	17.3
50	3.478	3.478	33.7	34.0
100	3.637	3.637	66.7	66.7




Мягкое отделение: синтетика



Метод	Test F1	ROC-AUC	Время, с	Итерации
Мягкий MDM	0.647	0.749	0.2997	310.9
Мягкий MDM-G	0.647	0.749	0.6601	313.4
Мягкий MDM-A	0.615	0.685	1.2505	255.1
Мягкий SMO	0.808	0.777	0.0362	1283.4
SVC	0.808	0.777	0.0018	–
LinearSVC	0.751	0.778	0.0004	3.5




Неразделимые данные: качество и время








Неразделимые данные: F1 по наборам





Неразделимые данные: F1 и размер выборки






Метод	Test F1	ROC-AUC	Время, с	Итерации
Мягкий MDM	0.823	0.919	1.5123	554.4
Мягкий MDM-G	0.823	0.920	3.1236	558.1
Мягкий MDM-A	0.822	0.921	6.3971	499.3
Мягкий SMO	0.815	0.909	0.2357	3421.5
SVC	0.844	0.924	0.1988	–
LinearSVC	0.846	0.925	0.0027	12.6




Реальные данные: качество и время







Реальные данные: F1 при разной доле объектов





Реальные данные: время при разной доле объектов





Реальные данные: F1 по наборам

Код	MDM	SMO	SVC	LinSVC	Код	MDM	SMO	SVC	LinSVC
R1	0.928	0.979	0.979	0.980	R9	0.676	0.651	0.651	0.653
R2	0.948	0.967	0.967	0.959	R10	0.985	0.967	0.967	0.974
R3	0.825	0.879	0.879	0.877	R11	1.000	1.000	1.000	1.000
R4	0.433	0.169	0.169	0.194	R12	0.893	0.989	0.989	0.989
R5	1.000	1.000	1.000	1.000	R13	0.825	0.904	0.904	0.914
R6	1.000	1.000	1.000	1.000	R14	0.656	0.897	0.897	0.894
R7	1.000	0.989	0.989	0.978	R15	0.545	0.224	0.647	0.639
R8	0.628	0.617	0.617	0.644	–	–	–	–	–

Среднее по R1–R15 скрывает неоднородность данных. На R14 (Spambase) SVM-решатели заметно лучше MDM, на R15 (a9a / Adult) собственный SMO проседает из-за лимита итераций, а на R4, R8 и R9 мягкий MDM остается конкурентным по F1.




Общая проверка различий

Блок	Метрика	n	p -value	Вывод
Разделимые	Итерации	36	$5.61 \cdot 10^{-23}$	значимо
Разделимые	Время	36	$1.05 \cdot 10^{-17}$	значимо
Неразделимые	Test F1	36	$7.96 \cdot 10^{-6}$	значимо
Неразделимые	ROC-AUC	36	0.034	значимо
Неразделимые	Время	36	$5.35 \cdot 10^{-37}$	значимо
Реальные	Test F1	90	$4.25 \cdot 10^{-6}$	значимо
Реальные	ROC-AUC	90	0.468	незначимо
Реальные	Время	90	$1.16 \cdot 10^{-91}$	значимо

Критерий Фридмана показывает, что различия между методами есть почти во всех блоках. Исключение – ROC-AUC на реальных данных: по ранжированию объектов методы близки, тогда как F1 и время различаются устойчиво.



Строгое отделение: парные проверки



Итерации относительно H1

Метод	Средн.	Δ	p_H
H3: MDM-G	690.2	+17.8	0.410
H4: MDM-A	565.7	-106.7	$4.28 \cdot 10^{-4}$
H5: треуг.	307.1	-365.3	$4.64 \cdot 10^{-6}$
H6: комб.	217.1	-455.3	$8.77 \cdot 10^{-7}$
H2: SMO	256.7	-415.7	$4.64 \cdot 10^{-6}$

Время относительно H1

Метод	Средн.	Δ	p_H
H3: MDM-G	0.0792	+0.0208	$8.77 \cdot 10^{-7}$
H4: MDM-A	0.0719	+0.0135	$4.17 \cdot 10^{-4}$
H5: треуг.	0.0533	-0.0051	0.496
H6: комб.	0.1259	+0.0675	0.496
H2: SMO	0.0068	-0.0516	$8.77 \cdot 10^{-7}$

Отрицательная разность означает выигрыш относительно базового MDM. Число итераций значительно уменьшают H4–H6 и H2, но по времени устойчивый выигрыш дает только SMO; для треугольного шага преимущество по времени статистически не подтверждается.



Мягкое отделение: парные проверки

Метод	F1	ΔF_1	p_H	$t, \text{с}$	Δt	p_H
MDM-G	0.647	+0.000	1.000	0.6601	+0.3605	$8.77 \cdot 10^{-7}$
MDM-A	0.615	-0.032	0.473	1.2505	+0.9509	$8.77 \cdot 10^{-7}$
SMO	0.808	+0.161	0.002	0.0362	-0.2635	$8.77 \cdot 10^{-7}$
SVC	0.808	+0.161	0.002	0.0018	-0.2978	$8.77 \cdot 10^{-7}$
LinearSVC	0.751	+0.105	0.003	0.0004	-0.2992	$8.77 \cdot 10^{-7}$

Сравнение проводится с базовым мягким MDM на N1–N4. MDM-G и MDM-A не дают значимого улучшения качества, зато увеличивают время. SVM-решатели значимо выигрывают по F1; по ROC-AUC картина такая же для SMO, SVC и LinearSVC.



Реальные данные: парные проверки

Метод	F1	ΔF_1	p_H	$t, \text{с}$	Δt	p_H
MDM-G	0.823	+0.0003	0.379	3.1236	+1.6113	$8.87 \cdot 10^{-16}$
MDM-A	0.822	-0.0005	0.613	6.3971	+4.8848	$8.87 \cdot 10^{-16}$
SMO	0.815	-0.007	0.613	0.2357	-1.2766	$8.87 \cdot 10^{-16}$
SVC	0.844	+0.021	0.017	0.1988	-1.3135	$8.87 \cdot 10^{-16}$
LinearSVC	0.846	+0.024	0.053	0.0027	-1.5096	$8.87 \cdot 10^{-16}$

На R1–R15 различия MDM, MDM-G и MDM-A по качеству не подтверждаются. SVC значимо превосходит MDM по F1 и ROC-AUC; у LinearSVC F1 выше, но после поправки Холма $p_H = 0.053$. По времени все отличия от MDM значимы.




SMO против библиотечных SVM

Блок	Метод	ΔF_1 к SMO	p_H	Вывод
N1–N4	SVC	0.000	1.000	качество совпадает
N1–N4	LinearSVC	-0.057	0.004	ниже SMO
R1–R15	SVC	+0.028	0.036	выше SMO
R1–R15	LinearSVC	+0.031	0.036	выше SMO

Блок	Метод	Δt к SMO, с	p_H
N1–N4	SVC	-0.0344	$3.51 \cdot 10^{-7}$
N1–N4	LinearSVC	-0.0358	$3.51 \cdot 10^{-7}$
R1–R15	SVC	-0.0369	$1.42 \cdot 10^{-12}$
R1–R15	LinearSVC	-0.2330	$5.48 \cdot 10^{-16}$


На синтетических неразделимых задачах собственный SMO воспроизводит качество SVC, но на реальных данных уступает библиотечным решателям. Главная причина видна на крупных и несбалансированных наборах: требуется более сильная эвристика выбора рабочей пары и контроль лимита итераций




- ▶ В строгой постановке различия касаются траектории оптимизации: H4–H6 и SMO значительно уменьшают число итераций относительно H1.
- ▶ Выигрыш по итерациям не всегда переходит во время: сложный геометрический шаг может быть дороже базового переноса веса.
- ▶ В мягкой постановке MDM-G и MDM-A не дают значимого улучшения F1 относительно мягкого MDM.
- ▶ На N1–N4 SVM-решатели статистически превосходят мягкий MDM по F1, а на R1–R15 устойчиво выигрывают прежде всего по времени.
- ▶ Средние значения по реальным данным нужно читать вместе с таблицей по R1–R15: Spambase и a9a дают основные разрывы между методами.




Интерпретация результатов



- ▶ В строгом отделении все методы приходят к корректной разделяющей геометрии, поэтому сравнение сводится к числу шагов и стоимости шага.
- ▶ Геометрические MDM-модификации полезны как исследовательский инструмент: они меняют траекторию, но требуют аккуратного учета цены одной итерации.
- ▶ В мягком отделении ускорение внутреннего цикла само по себе не гарантирует лучшую границу классификации.
- ▶ На реальных бинарных данных библиотечные SVM-решатели остаются более устойчивыми прикладными методами, особенно на Spambase и a9a.
- ▶ Для собственной реализации SMO главный резерв – выбор рабочей пары; для MDM – векторизация и более сильная soft-модификация.



- ▶ MDM даёт наглядную геометрическую интерпретацию линейного разделения через ближайшие точки выпуклых оболочек.
- ▶ В строгой постановке MDM и SVM приходят к одной геометрии максимального зазора.
- ▶ Проверки гипотез подтвердили, что часть MDM-модификаций значительно уменьшает число итераций, но не всегда даёт выигрыш по времени.
- ▶ В мягкой постановке SVM-решатели значительно выигрывают по F1 на неразделимой синтетике, а на реальных данных лучше масштабируются по времени.
- ▶ Soft-варианты MDM близки по качеству, поэтому дальнейшая работа должна быть направлена на ускорение вычислений и изменение самой траектории построения гиперплоскости.



Спасибо за внимание

Санкт-Петербургский государственный
экономический университет

Вопросы

UNECON.RU